
EDA 및 전처리

1. 데이터 시각화





개요


matplotlib 기본 차트
matplotlib customization
matplotlib with pandas
seaborn package


개요

- ✓ 목표
- ✓ 데이터 시각화란?

Data Visualization

- ✓ 수많은 데이터를 한눈에 파악하는 두 가지 방법
 - 기초 통계량
 - 데이터 시각화
- ✓ Very important in Data Analysis
 - 데이터 탐색.(EDA)
 - 데이터로부터 얻은 인사이트 보고.





목표


- 1. matplotlib 패키지의 기본 함수들을 사용할 수 있습니다.
- 2. 각 차트별로 원래 목적에 맞게 사용할 수 있습니다.
- 3. 기본 차트에 축 레이블, 타이틀 등을 추가할 수 있습니다.
- 4. seaborn 패키지를 이용하여 분석용 차트를 구성할 수 있습니다.

matplotlib 기본 차트

- ✓ Basic plot
- ✓ Scatter
- ✓ Histogram
- ✓ Boxplot
- ✓ Bar chart
- ✓ Pie chart

Basic Plot

- ✓ matplotlib의 subpackage인 pyplot
- ✓ plt.plot : Line Chart
 - 보통 날짜(시간) 축(X축)의 변화에 따른 연속형 변수 값의 추세를 살펴볼 때 사용
 - plt.plot(x축, y축)




```
import matplotlib.pyplot as plt
year = [1950, 1970, 1990, 2010]
pop = [2.519, 3.692, 5.263, 6.972]
plt.plot(year, pop)
plt.show()
```

```
year = [1950, 1970, 1990,
                             2010]
      [2.519, 3.692, 5.263, 6.972]
```

Scatter Plot

✓plt.scatter():

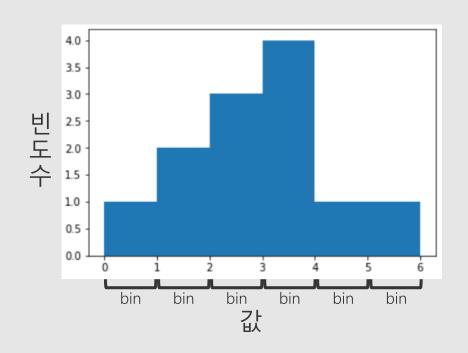
- 두 연속형 변수의 값의 분포(상관관계)를 살펴볼 때 사용
- 두 연속형 변수의 비 : 비율 KPI(생산성, 영업이익율 등)
- plt.scatter(x축, y축)



```
import matplotlib.pyplot as plt
year = [1950, 1970, 1990, 2010]
pop = [2.519, 3.692, 5.263, 6.972]
plt.scatter(year, pop)
plt.show()
```

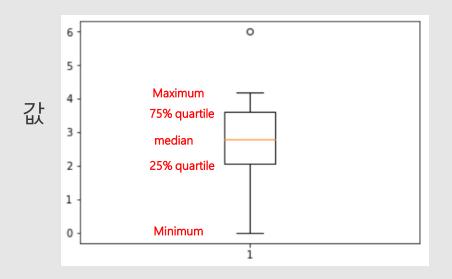
Histogram

✓ 연속형 변수의 분포를 살펴볼 때 사용



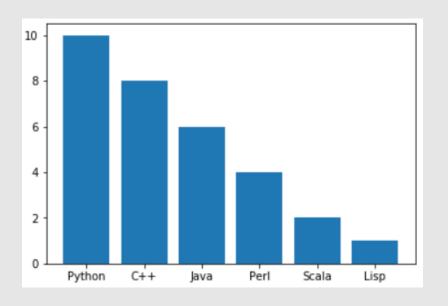
Box Plot

✓ 연속형 변수의 분포를 살펴볼 때 사용



Bar plot

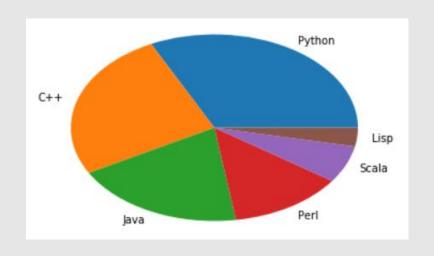
✓ 범주형 변수끼리 연속형 값을 비교하기 위해 사용



import numpy as np objects = ('Python', 'C++', 'Java', 'Perl', 'Scala', 'Lisp') performance = [10,8,6,4,2,1] plt.bar(objects, performance) plt.show()

Pie Chart

✓ 범주형 변수끼리 연속형 값의 비율을 비교하기 위해 사용



import numpy as np objects = ('Python', 'C++', 'Java', 'Perl', 'Scala', 'Lisp') performance = [10,8,6,4,2,1] plt.pie(performance, labels =objects) plt.show()

Customization

- ✓ Axis Labels & Title
- ✓ Ticks
- ✓ Common Axis
- ✓ Subplot


Axis Label & Title

✓ Axis Label

- X축 : plt.xlabel('레이블 이름')
- Y축 : plt.ylabel('레이블 이름')

✓ Title

■ plt.title('타이틀 이름')




```
import matplotlib.pyplot as plt
year = [1950, 1970, 1990, 2010]
pop = [2.519, 3.692, 5.263, 6.972]
plt.plot(year, pop)
# label
plt.xlabel('Year')
plt.ylabel('Population')
# Title
plt.title('World Population Projections')
plt.show()
```


Ticks

✔ Ticks : 축의 값 범위를 지정/변환

■ X축 : plt.xticks([값 범위]) ■ Y축 : plt.yticks([값 범위])


```
# Ticks
plt.yticks([0, 2, 4, 6, 8, 10])
```





Common Axis


- ✓ x축의 값을 맞춰주고
- ✓ 두 개의 플롯을 그리면 축을 공유



```
year = [1950, 1970, 1990, 2010]
pop1 = [2.519, 3.692, 5.263, 6.972]
pop2 = [1.231, 2.252, 2.988, 4.334]
plt.plot(year, pop1, 'red')
plt.plot(year, pop2, 'blue')
# label
plt.xlabel('Year')
plt.ylabel('Population')
# Title
plt.title('World Population Projections')
plt.show()
```

Subplot

- ✓ 두개 이상의 차트를 한 화면에 표현
- ✓ subplot(nrows, ncolumns, index)



Python # plot1 plt.**subplot**(2, 1, 1) plt.plot(year, pop1, 'red') plt.xlabel('Year') plt.ylabel('Population') plt.title('Pop1') # plot2 plt.**subplot**(2, 1, 2) plt.plot(year, pop2, 'blue') plt.xlabel('Year') plt.ylabel('Population') plt.title('Pop2') plt.tight_layout() plt.show()

matplotlib with pandas

dataframe with plot


- ✓ Pandas의 Series나 Dataframe은 plot이라는 method를 내장
- ✓ plot은 matplotlib를 내부적으로 Import하여 사용
- ✓ 종류
 - .plot()
 - .plot.bar()
 - .pie()
 - .hist()
 - .plot.kde()
 - .boxplot()
 - .scatter()
 - area()

Scatter

✓ Dataframe에 메소드로 plot을 붙여서 바로 차트를 그려볼 수 있다.

aq.head()						
	Ozone	Solar.R	₩ind	Temp	Month	Day
0	41.0	190.0	7.4	67	5	1
1	36.0	118.0	8.0	72	5	2
2	12.0	149.0	12.6	74	5	3
3	18.0	313.0	11.5	62	5	4
4	NaN	NaN	14.3	56	5	5


```
aq = pd.read_csv("airquality.csv")
aq.plot(kind = "scatter", x= "Temp", y = "Ozone")
```



histogram


✓ Dataframe에 메소드로 plot을 붙여서 바로 차트를 그려볼 수 있다.


```
ti = pd.read_csv("titanic_sample.csv")
ti.plot(kind = "hist", y = "Age", bins = 16)
```



Barplot with group by

```
ti = pd.read_csv("sample_data/titanic_simple.csv")
ti.groupby("Sex")['PassengerId'].count().plot(kind = 'bar')
ti.groupby(["Pclass","Sex"])["Age"].mean().plot(kind = "bar")
```





boxplot

Python


ti.plot(kind = "box", y ="Age")

80 0 70 60 50 40 30 20 10 0 -Age

Python

ti.boxplot("Age", by ="Survived")

Boxplot grouped by Survived



seaborn package

seaborn 패키지 개요

- ✓ seaborn은 matplotlib 기반으로 다양한 색상과 차트 기능을 추가한 시각화 패키지
- ✓ matplotlib에서 제공하지 않는 통계 차트들 제공

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```


distplot(Density plot & histogram)


Python

```
# Density plot만 그리기
sns.kdeplot(aq["Ozone"])
plt.show()
```


Python

distplot으로 densityplot과 histogram 함께그리기 sns.distplot(aq[aq["Ozone"].notnull()]["Ozone"]) plt.show()







countplot vs. barplot



Box plot

```
sns.boxplot(x="Pclass", y="Age", hue="Survived", data=ti)
sns.boxplot(y="Pclass", x="Age", hue="Survived", data=ti, orient = 'h'
, palette = "Set3")
```






Scatterplot

Python


sns.scatterplot(x="Fare", y="Age", hue="Survived", data=ti)



특별한 Chart : jointplot


✔ Histogram과 Scatter가 같이 표현

Python sns.jointplot(x="Fare", y="Age", data=ti)



Python_

sns.jointplot(x="Temp", y="Ozone"
, data=aq, kind = 'kde')



특별한 Chart : pairplot

✓ 상관관계를 살펴볼때.

Python sns.pairplot(aq2 , vars = ['Ozone','Wind','Temp']) 150 50 20 100 20 100 150 80 100 Wind Ozone

Python

sns.pairplot(ti2, vars = ['Age','Fare']
, hue = "Survived")

